📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호	10705	이름	김연우	제출일 . . .

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① **"Orange3 선형회귀 탐구"** 입니다. 만점 **30**점 · 기본점수**9**점 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. ※ **AI(생성형 AI 포함)** 활용은 원칙적으로 금지합니다.

영역 1 데이터 이해 및 회귀식 추정 [10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 어떤 관계를 예측해 볼까? 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 x → 종속변수 y)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

탐구 주제	웹 서버의 동시 접속자 수에 따른 응답 지연 시간
독립변수 **x**	동시 접속자 수(명)
종속변수 **y**	응답 지연 시간(밀리초)
데이터 출처	Kaggle 사이트 (https://www.kaggle.com/datasets/kevinkonstas/server-load-dataset?resource=download)
예상 관계	x가 커지면 y는 증가할 것이다. 왜냐하면 서버의 동시 접속자 수 가 많을 수록 서버에 과부하가 걸리기 때문이다.

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 **x** (동시 접속자 수)	종속변수 **y** (응답 지연 시간)
9007	724.22
6634	492.92
9520	862.41
4209	612.55
2792	353.45
4362	391.14
3647	256.03
2666	400.68

	A	B
1	Concurrent_Sessions	Response_Time_ms
2	9007	724.22
3	6634	492.92
4	9520	862.41
5	4209	612.55
6	2792	353.45
7	4362	391.14
8	3647	256.03
9	2666	400.68
10		
11		

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 y = a x + b 로 손으로 추정해 보세요.

x가 한 단위 커질 때 y는 약 0.1만큼 증가한다. 기울기 a ≈0.1, 절편 b ≈-100. 따라서 y = 0.1 x -100 으로 예상한다.

1-3 기울기와 절편의 의미 해석

기울기 a는 이 데이터에서 한명당 지연시간을 의미한다. 절편 b는 x=0일 때는 동시 접속자 수가 없을 때이다.

영역 2	Orange3 예측 모델 구성	[10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

독립변수 **x**	종속변수 **y** (비움)
2000	?
4000	?
5000	?
7000	?
10000	?

2-2 Orange3 워크플로우 구성하기

📌 워크플로우 순서

① File 위젯 → train.csv 불러오기 (이름: train data)

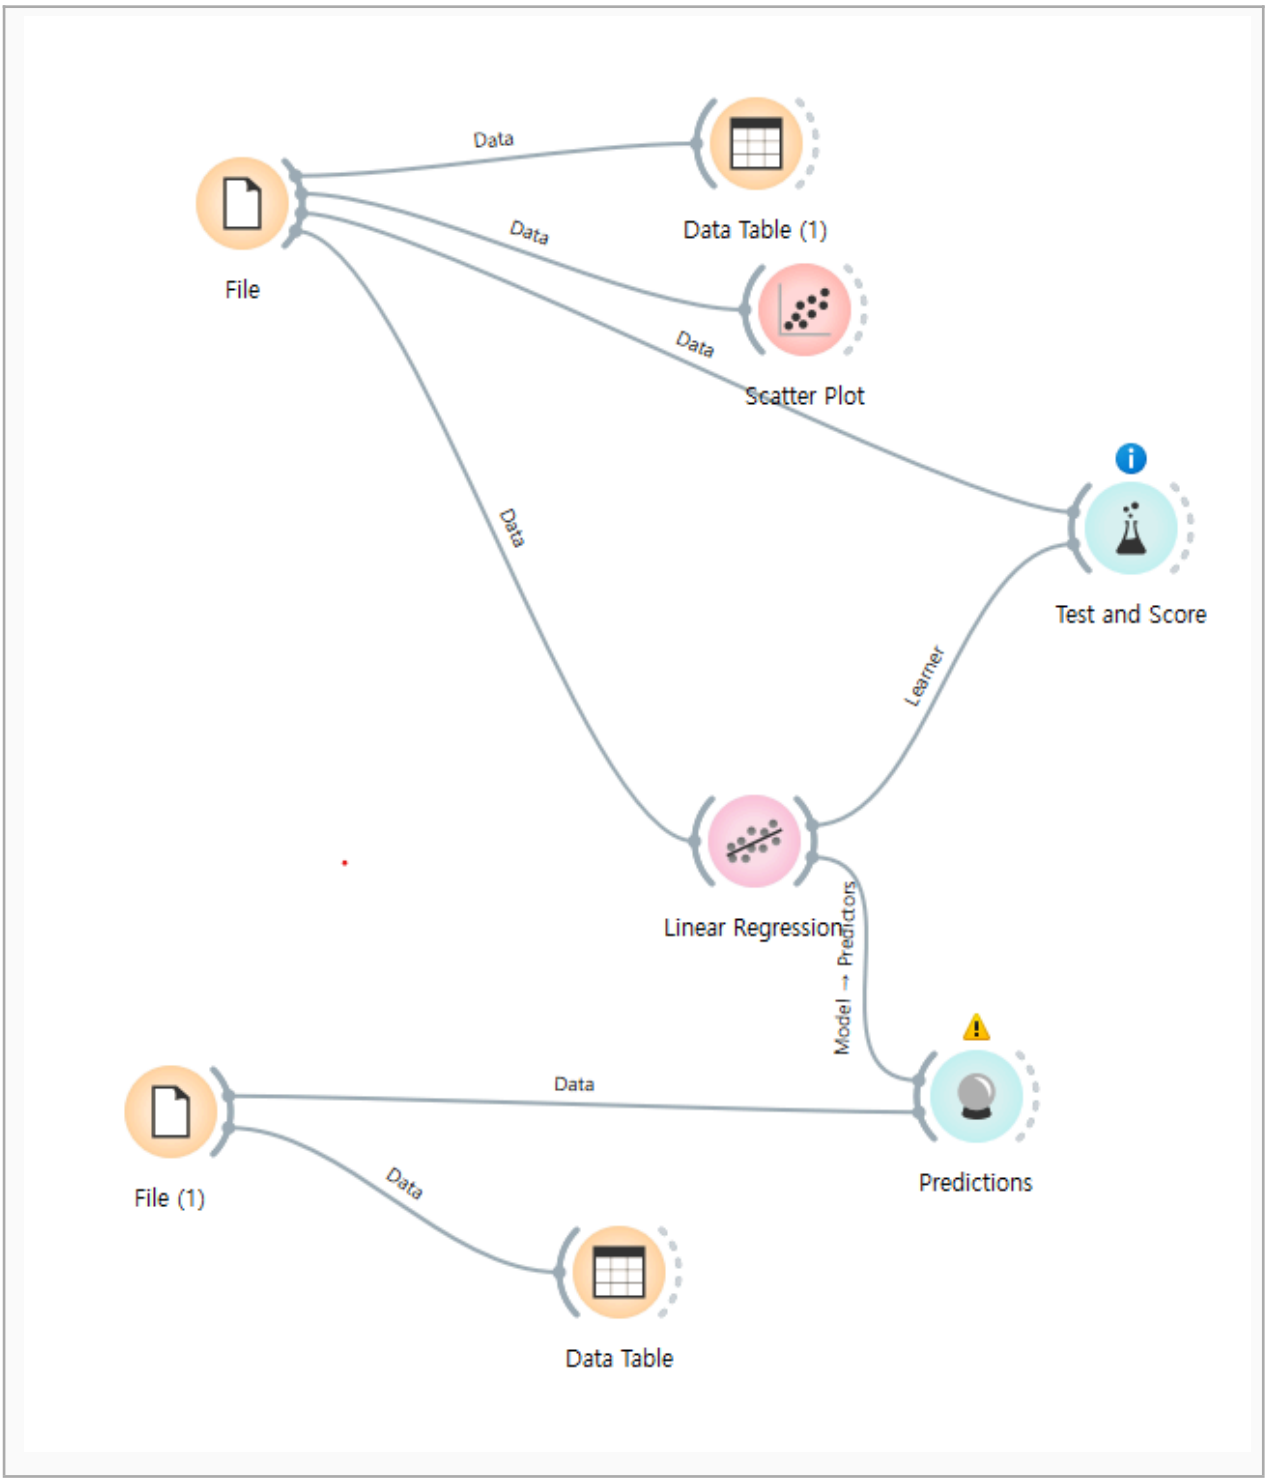
② Data Table 위젯 연결 → 데이터 확인

③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)

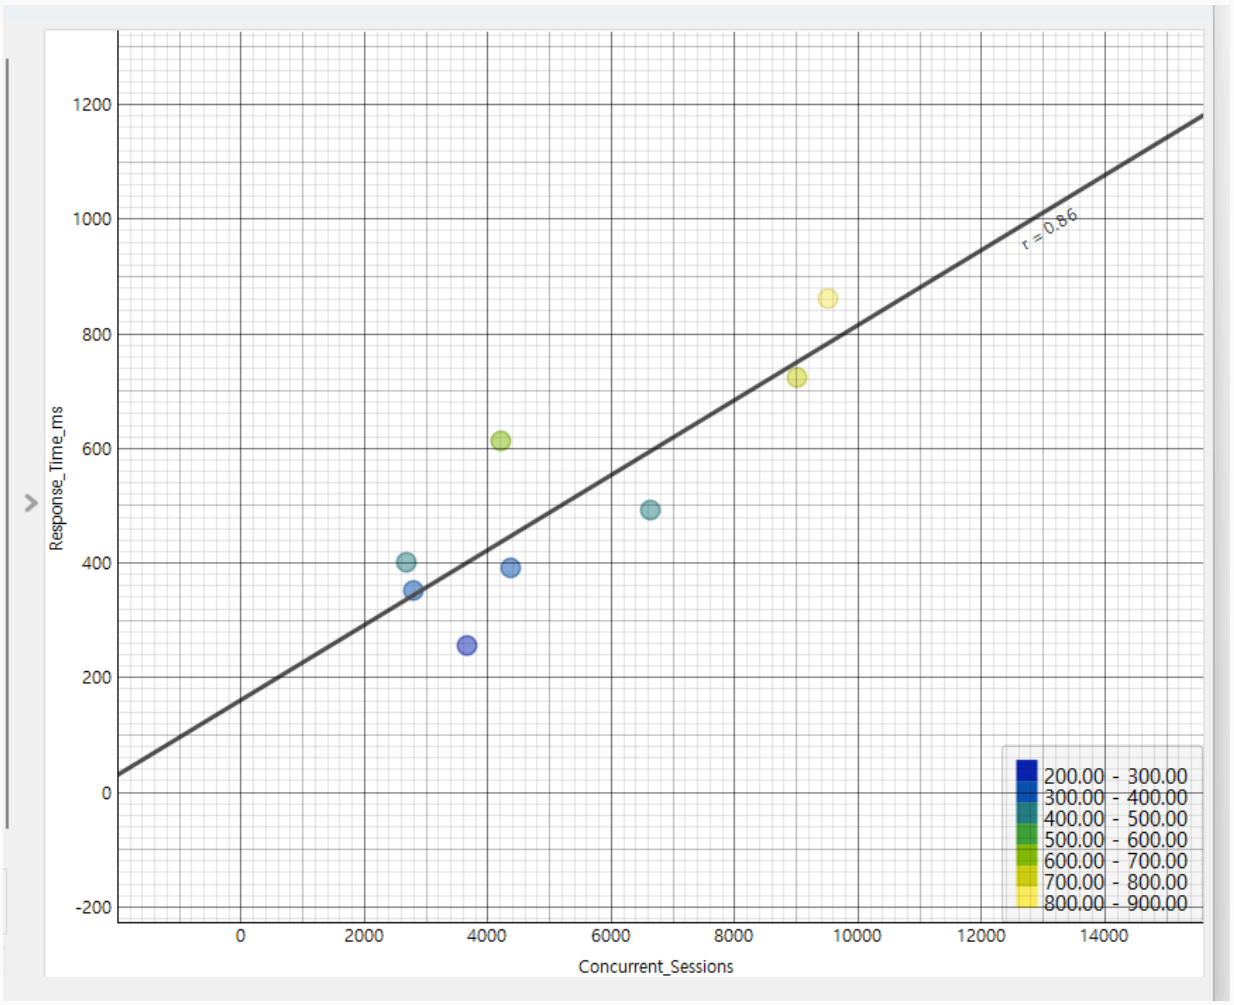
④ Linear Regression 위젯 연결 → 모델 학습

⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)

⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결


Data
Data Table (1)
File
Data
Data
Scatter Plot
Data
Test and Score
Learner
Linear Regression
Model → Predictors
Data
Predictions
File (1)
Data
Data Table

산점도 확인 및 관찰



점들이 대부분 중간 정도에 있고 우상향하는 그래프가 그려지며 기울기는 중간 정도의 기울기를 가진다.

2-3 예측 결과 비교 (내 손 계산 vs Orange3)

📷 Predictions 위젯의 예측 결과 화면을 캡처		
x 값	내가 계산한 예측값 **(y=ax+b)**	**Orange3** 예측값
2000	100	292.6
4000	300	423.07
5000	400	488.48
7000	600	619.29
10000	900	815.51

영역 **3**	결과 검증 및 해석	**[10점]**

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

내 손 계산값과 Orange3 예측값이 오차가 있긴 하지만 대부분 크지 않고 비슷한 것도 있다. 예측 점들이 산점도의 회귀선 근처에 놓인다. 앞선 예시를 보고 학습하여 최대 비슷한 값으로 추정한 것이기에 잘 판단했다.

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score**로 모델의 신뢰도를 '숫자'로 검증하기

① **[Evaluate] → [Test and Score]** 위젯을 추가한다.

② **train data(File)**를 **Data**로, **Linear Regression**을 **Learner**로 각각 연결한다.

③ 평가 방법은 **Cross validation(**교차검증**,** 기본값**)**으로 두고 아래 세 지표를 읽어 기록한다.

(MSE·MAPE도 함께 나오지만 **R²·MAE·RMSE**에 집중**. RMSE = MSE**의 제곱근**)**

평가지표	내가 기록한 값	이 값이 뜻하는 것 **(**내 해석**)**
R² (결정계수**)**	0.56	동시 접속자 수가 지연 시간에 미치는 영향은 **56%** 정도이다.

MAE (평균오차)	11	평균적으로 11의 오차가 있다.
RMSE	127	MAE가 11인데 RMSE가 127이라는 것은 이상치가 존재한다는 뜻이다.

① R^2이 0.56으로 가깝지 않다.
② 평균에 크게 벗어난 이상치가 존재해서 RMSE의 값이 MAE보다 크다
③ Test and Score 점수가 전체 데이터에 그냥 맞췄을 때 보다 조금 낮은 이유는 다른 여러 요인이 작용하기도 하고 일부 값으로 모든 값을 정의 내리지 못하기 때문이다.
위 내용을 정리하면 결정계수가 1에 가깝지도 않고 크게 벗어난 이상치도 존재 함으로 참고는 가능하지만 일치하진 않는다.

3-2 결과 해석 — 숫자 뒤의 의미

x와 y는 정비례 관계이다. 기울기의 크기가 증가 할수록 한명이 늘어날 때 마다 서버의 접속시간이 느려진다. 이러한 결과를 통해 동시 접속자 수를 예측하여 서버의 속도가 얼마만큼 느려지는지 알 수 있다.

3-3-1 한계 탐구 — 극단값 실험 (외삽의 위험)

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요?
외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 **x** 값	모델 예측값 **y**	현실적으로 가능한가**?**
-3000	-34.78	불가능
1000000	65568.42	불가능

에당초에 동시 접속자 수는 음수로 존재 할수 없다. 동시 접속자 수가 100만명일 때 약65000밀리초 즉 65초나 걸리는데 이는 서버가 과부하되어서 서버가 터져버리기 떄문에 신뢰 할 수 없다. 실제 학습에 사용한 약2000~ 9000명 내외 정도 신뢰 할수 있다.

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 활동 성찰 — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

처음에 할 때는 자료가 너무 많아서 이것보다 더 독특한 이상치가 섞여 값이 이상하게 나왔다. 이를 해결하기 위해 그나마 가장 규칙적이었던 값들을 찾고 비정상적인 이상치는 제외 하였다. 또한 이렇게

했음에도 값이 예측과 벗어나거나 생각과 다른 점이 많았다. 나는 이것을 보고 선형 회귀는 제대로 값을 예측 하려면 더욱더 규칙적인 값들만을 찾아야하고 실제 값은 예상과 다를 수 있음으로 주의해야 하는 것을 배웠다.

📚 핵심 개념 요약

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : $y = ax + b$ 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : $a>0$이면 양의 관계(정비례), $a<0$이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30**점	기본점수 9점	**/ 30**